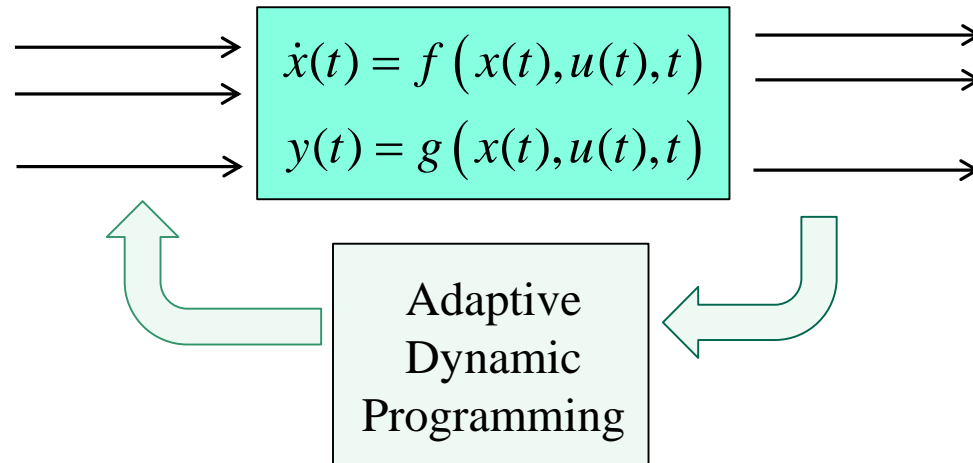


מערכות מכטרוניות


מבוא לבקרה אופטימלית - חלק 2

Introduction to Optimal Control



מרצה: שי ארוגטי

בקר משוב מצב אופטימלי



מצגת זו מתבססת (עם תוספות ממקורות אחרים) על פרקים 1, 2, 3 בספר,

Robust Adaptive Dynamic Programming, First Edition
By, Yu Jiang Zhong-Ping Jiang, Wiley, 2017.

CHAPTER 1 - Introduction

CHAPTER 2 - Adaptive Dynamic Programming for Uncertain
Linear Systems

CHAPTER 3 - Semi-Global Adaptive Dynamic Programming

מומלץ גם לקרוא את המאמרים (מציגים חומר דומה),

Y. Jiang and Z. P. Jiang. "Computational adaptive optimal control for continuous-time linear systems with completely unknown dynamics," Automatica, 48(10), 2012.

Y. Jiang and Z. P. Jiang. Robust adaptive dynamic programming and feedback stabilization of nonlinear systems. IEEE Transactions on Neural Networks and Learning Systems, 25(5), 2014.

בקר משוב מצב אופטימלי

פיתוח הבקר האופטימלי הסטציונרי באופן ישיר

תחילה נוכיח את המשפט הבא המשווה בין פתרונות של שתי משוואות ריקטי,

(Comparison Theorem)

$$A^T P_1 + P_1 A - P_1 \bar{R} P_1 + \bar{Q}_1 = 0 \quad \text{נניח,}$$

$$A^T P_2 + P_2 A - P_2 \bar{R} P_2 + \bar{Q}_2 = 0$$

$$\bar{Q}_2 \geq \bar{Q}_1 \geq 0 \quad \text{כאשר}$$

$$P_1 = P_1^T, \quad P_2 = P_2^T, \quad P_1 \neq P_2, \quad \bar{Q}_2 \neq \bar{Q}_1 \quad \text{יתקבלו פתרונות שונים,}$$

$$\bar{R} \geq 0 \quad \text{ו-} \quad A - \bar{R} P_2 \quad \text{היא מטריצה יציבה.}$$

$$\bar{R} = B R^{-1} B^T \quad \text{נזכיר כי במקרה של הבקר האופטימלי,}$$

$$A - \bar{R} P = A - B R^{-1} B^T P \quad \text{לכן,} \quad \text{(החוג הסגור)}$$

ניתן להראות כי ביחס לשתי משוואות הריקטי הנתונות **מתקבל**, $P_2 \geq P_1$.

בקר משוב מצב אופטימלי

פיתוח הבקר האופטימלי הסטציונרי באופן ישיר - המשך

נתון התהליך הבא (מסוג LTI) $\dot{x}(t) = Ax(t) + Bu(t), \quad x(0) = x_0$

נניח כי ידוע שהבקר האופטימלי הוא מסוג משוב מצב, לכן, $u(t) = -Kx(t)$

אנו מעוניינים בהגבר K כך שלפונקציית המחיר הבאה ערך מינימלי,

$$J = \int_0^\infty \left(x^T(t) Q x(t) + u^T(t) R u(t) \right) dt$$

כאשר, $Q \geq 0, \quad R > 0$

הצמד (A, B) ניתן לייצוב (סטביליזבילי).

מודל החוג הסגור עם בקר משוב מצב כלהו, $\dot{x}(t) = (A - BK)x(t), \quad x(0) = x_0$

לכן עבור כל מטריצת הגברים K , יתקבל, $x(t) = e^{(A-BK)t} x_0$

בקר משוב מצב אופטימלי

פיתוח הבקר האופטימלי הסטציונרי באופן ישיר

את הפתרון של החוג הסגור, עבור משוב מצב כלשהו (K) ניתן להציב בפונקציית המחיר

$$\begin{aligned} J &= \int_0^\infty \left(x^T(t) Q x(t) + u^T(t) R u(t) \right) dt \\ &= \int_0^\infty \left(x^T(t) Q x(t) + x^T(t) K^T R K x(t) \right) dt \\ &= \int_0^\infty \left(x^T(t) (Q + K^T R K) x(t) \right) dt \\ &= x_0^T \left(\int_0^\infty \left(e^{(A-BK)^T t} (Q + K^T R K) e^{(A-BK)t} \right) dt \right) x_0 \end{aligned}$$

ברור כי רק בקר מייצב, מאפשר ערך סופי של פונקציית המחיר ובמקרה זה ניתן לסמן,

$$J = x_0^T P x_0, \quad \text{וגם} \quad P = \int_0^\infty \left(e^{(A-BK)^T t} (Q + K^T R K) e^{(A-BK)t} \right) dt$$

לכן ברור שאנו מחפשים את הבקר K עבורו ה- P היא מינימלית.

בקר משוב מצב אופטימלי

פיתוח הבקר האופטימלי הסטציונרי באופן ישיר

נזכיר כי הפתרון של משוואות ליאפונוב מהצורה,

$$\bar{A}^T P + P \bar{A} = -\bar{Q}$$

עבור מטריצה \bar{A} יציבה הינו,

$$P = \int_0^\infty e^{\bar{A}^T t} \bar{Q} e^{\bar{A} t} dt$$

לכן ברור שהמטריצה P שהצגנו בשקף הקודם היא פתרון של משוואת ליאפונוב מהצורה,

$$(*) \quad (A - BK)^T P + P(A - BK) = -Q - K^T R K$$

קל יותר לפתור משוואות ליאפונוב (כלומר למצוא את P), אבל המשוואה הזאת מנוסחת ביחס למטריצה \bar{A} של החוג הסגור (עם בקר שעדיין לא ידוע).

לכן, נפתח את הסוגריים ונשנה את מבנה המשוואה במטרה למצוא את P .


בקר משוב מצב אופטימלי

פיתוח הבקר האופטימלי הסטציונרי באופן ישיר

$$(A - BK)^T P + P(A - BK) = -Q - K^T R K \quad \text{נזכיר,}$$

$$A^T P + PA - \underbrace{(BK)^T P - PBK + K^T R K}_{\text{נבצע כאן השלמה לריבוע}} + Q = 0 \quad \text{לכן,}$$

נבצע כאן השלמה לריבוע



$$A^T P + PA - \underbrace{PBR^{-1}B^T P}_{\bar{R}} + \underbrace{(R^{-1}B^T P - K)^T R (R^{-1}B^T P - K)}_{\bar{Q}} + Q = 0$$

זוהי משוואת ריקטי, וסמנו את ה- \bar{Q} וה- \bar{R} שהופיעו בניסוח של ה- Comparison Theorem.

מתוך ה- Comparison Theorem אנו יודעים ש- P מינימלית תתקבל כאשר \bar{Q} מינימלי.

הבקר האופטימלי הוא הבקר עבורו P מינימלי, לכן הגבר הבקר האופטימלי הוא $K = R^{-1}B^T P$.

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

תכנון הבקר האופטימלי דורש פתרון של משוואות ריקטי, זוהי משוואה ריבועית ב- P .

משוואת ליאפונוב היא משוואה ליניארית ב- P , לכן יותר קלה לפתרון.

ניתן להחליף את הפתרון של משוואת ריקטי בתהליך איטרטיבי בוא פותרים משוואת ליאפונוב.

הפתרונות בתהליך האיטרטיבי מתכנסים (באופן מונוטוני ועם קצב התכנסות ריבועי בקרבת הפתרון) לפתרון של משוואת ריקטי, כלומר לפתרון האופטימלי.

שיטת פתרון זו מתבססת על מאמר של David L. Kleinman מ-1968, ומהווה בסיס לשיטות תכנון רבות בגישה של Reinforcement learning.

בבסיס השיטה נמצאת משוואת הליאפונוב שהצגנו קודם,

$$(A - BK)^T P + P(A - BK) + Q + K^T R K = 0 \quad (\text{משוואה } (*))$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי (המשך)

עבור K_i מייצב מסוים (יחד עם $(A, Q^{1/2})$ דטקטבילי), ניתן לפתור את המשוואה,

$$(*) \quad (A - BK_i)^T P_i + P_i (A - BK_i) + Q + K_i^T R K_i = 0$$

ולקבל $P_i > 0$.

משפט (Kleinman 1968)

נניח $P_i, i = 1, 2, \dots$ הם פתרונות (מוגדרים חיובית) של $(*)$, כאשר באופן רקורסיבי,

$$K_i = R^{-1} B^T P_{i-1}$$

ו- K_0 הינו פתרון מייצב (כלומר המטריצה $(A - BK_0)$ יציבה), אז,

$$1) \quad P \leq P_i \leq P_{i-1} \leq \dots, \quad i = 0, 1, \dots$$

$$2) \quad \lim_{i \rightarrow \infty} P_i = P$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי (המשך)

דוגמא

המודל הבא מתאר את שגיאות העקיבה שלי כלי רכב ביחס למסלול רצוי (קו ישר).

(מתוך -Rajesh Rajamani, "Vehicle Dynamics and Control", 2012, פרק 2 ע"מ 36)

$$\begin{bmatrix} \dot{e}_1 \\ \ddot{e}_1 \\ \dot{e}_2 \\ \ddot{e}_2 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & -2 \frac{C_{\alpha 2} + C_{\alpha 1}}{mv_x} & 2 \frac{C_{\alpha 2} + C_{\alpha 1}}{m} & -2 \frac{C_{\alpha 2} l_2 - C_{\alpha 1} l_1}{mv_x} \\ 0 & 0 & 0 & 1 \\ 0 & -2 \frac{C_{\alpha 2} l_2 - C_{\alpha 1} l_1}{I_{zz} v_x} & 2 \frac{C_{\alpha 2} l_2 - C_{\alpha 1} l_1}{I_{zz}} & -2 \frac{C_{\alpha 2} l_2^2 + C_{\alpha 1} l_1^2}{I_{zz} v_x} \end{bmatrix} \begin{bmatrix} e_1 \\ \dot{e}_1 \\ e_2 \\ \dot{e}_2 \end{bmatrix} + \begin{bmatrix} 0 \\ \frac{2C_{\alpha 2}}{m} \\ 0 \\ \frac{2C_{\alpha 2} l_2}{I_{zz}} \end{bmatrix} \delta$$

במודל, $e_1(t)$ - שגיאת מקום (של כלי הרכב ביחס למסלול הרצוי).

$e_2(t)$ - שגיאת בכיוון (של כלי הרכב ביחס למסלול הרצוי).

$\delta(t)$ - זווית היגוי (אות הבקרה).

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי (המשך)

clc, close all

% Car Parameters

m=1573; Iz=2873; l1=1.58; l2=1.1; lh=7;
Ca1=80000; Ca2=80000; vx=25;

% State Space model

A_22=-2*(Ca2+Ca1)/(m*vx);
A_23= 2*(Ca2+Ca1)/m;
A_24=-2*(Ca2*l2-Ca1*l1)/(m*vx);
A_42=-2*(Ca2*l2-Ca1*l1)/(Iz*vx);
A_43= 2*(Ca2*l2-Ca1*l1)/Iz;
A_44=-2*(-Ca2*((l2)^2)+Ca1*((l1)^2))/(Iz*vx);

B2=2*Ca2/m;

B4=2*Ca2*l2/Iz;

A=[0 1 0 0; 0 A_22 A_23 A_24; 0 0 0 1; 0 A_42 A_43 A_44];

B=[0; B2; 0; B4];

n=4; % state dimension

% Weighting matrices

q11=1; q12=0; q21=0; q22=0;

Q=diag([q11,q12,q21,q22]);

R=1;

דוגמא (המשך)

בחלק זה של התוכנית, מגדירים את המודל ואת מטריצות המשקל.

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי (המשך)

% Model-base design with Riccati equation

[K1,P1,E1]=lqr(A,B,Q,R); K1

%%% Model-base design with Lyapunov equation

K_i=K1*0.4; eig(A-B*K_i);

P_i_old=zeros(size(A));

KK=[]; ii=[]; nPi=[];

for i=1:20

AA=A-B*K_i; QQ=Q+K_i'*R*K_i;

P_i=lyap(AA',QQ); norm(P_i); nPi=[nPi norm(P_i)];

K_i=inv(R)*B'*P_i;

if norm(P_i_old-P_i)<0.01

KK=[KK K_i']; ii=[ii i];

break

end

P_i_old=P_i;

KK=[KK K_i']; ii=[ii i];

end

K2=K_i

figure(1)

plot(ii,KK',ii,KK','*',[ii(1) ii(end)],[K1' K1'],'--','linewidth',1)

title('Data-based Off-policy, unknown A,B')

xlabel('Iterations'), ylabel('Control gains'), grid

figure(2)

plot(nPi,'linewidth',1)

xlabel('Iterations'), ylabel('P-norm'), grid

דוגמא (המשך)

K_1 - מחושב עם הפקודה **lqr** (מייצג את הערכים האופטימליים)

K_2 - חושב עם האלגוריתם של Kleinman (ללא הפקודה **lqr**). מוצגת התוצאה שהתקבלה אחרי 6 איטרציות.

K1 =
1.0000 0.0901 1.9791 0.1333

K2 =
1.0000 0.0901 1.9791 0.1333

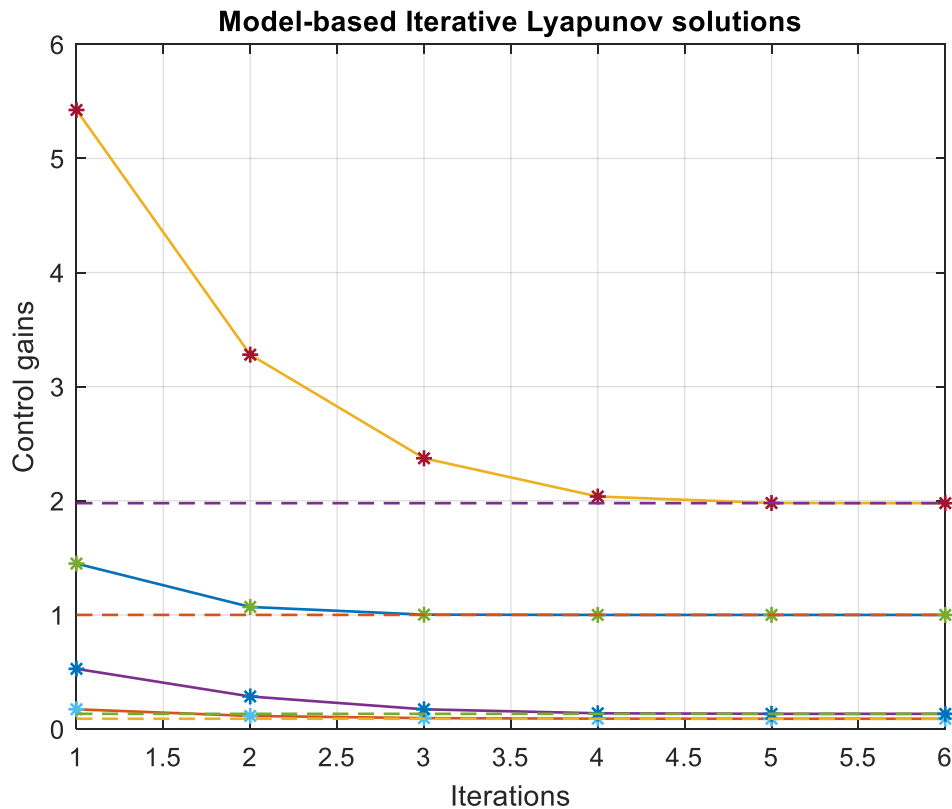
fx >> |

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי (המשך)

דוגמא (המשך)

Figure 1




התכנסות הגברי הבקר אל
הערכים האופטימליים (מוצגות
6 איטרציות).

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי (המשך)

דוגמא (המשך)

Figure 2



דעיכה מונוטונית של הנורמה של המטריצה P .

נזכיר כי לפתרון האופטימלי P עם נורמה מינימלית.

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

מכפלת קרוניקר - Kronecker product

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots \\ a_{21} & a_{22} & \\ \vdots & & \ddots \end{bmatrix}, \quad B = \begin{bmatrix} b_{11} & b_{12} & \cdots \\ b_{21} & b_{22} & \\ \vdots & & \ddots \end{bmatrix}$$

נניח שתי מטריצות, הממדים
לא בהכרח זהים

מכפלת קרוניקר מסומנת ב- \otimes ומוגדרת באופן הבא,

$$A \otimes B = \begin{bmatrix} a_{11}B & a_{12}B & \cdots \\ a_{21}B & a_{22}B & \\ \vdots & & \ddots \end{bmatrix} = \begin{bmatrix} a_{11} \begin{bmatrix} b_{11} & b_{12} & \cdots \\ b_{21} & b_{22} & \\ \vdots & & \ddots \end{bmatrix} & a_{12} \begin{bmatrix} b_{11} & b_{12} & \cdots \\ b_{21} & b_{22} & \\ \vdots & & \ddots \end{bmatrix} & \cdots \\ a_{21} \begin{bmatrix} b_{11} & b_{12} & \cdots \\ b_{21} & b_{22} & \\ \vdots & & \ddots \end{bmatrix} & a_{22} \begin{bmatrix} b_{11} & b_{12} & \cdots \\ b_{21} & b_{22} & \\ \vdots & & \ddots \end{bmatrix} & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

מכפלת קרוניקר - Kronecker product

לדוגמא,

$$A = \begin{bmatrix} 1 & 2 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad A \otimes B = \begin{bmatrix} 1 & 2 & 2 & 4 \\ 3 & 4 & 6 & 8 \end{bmatrix}$$

או,

$$A = \begin{bmatrix} 1 & 2 \end{bmatrix}, \quad B = \begin{bmatrix} 3 & 4 \end{bmatrix}, \quad A \otimes B = \begin{bmatrix} 3 & 4 & 6 & 8 \end{bmatrix}$$

תכונות מעניינות של מכפלת קרוניקר (נדגיש כי $A \otimes B \neq B \otimes A$),

$$A \otimes (B + C) = A \otimes B + A \otimes C$$

$$(A \otimes B)(C \otimes D) = (AC) \otimes (BD)$$

$$(kA) \otimes B = A \otimes (kB) = k(A \otimes B)$$

$$(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$$

$$(A \otimes B) \otimes C = A \otimes (B \otimes C)$$

$$(A \otimes B)^T = A^T \otimes B^T$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

מכפלת קרוניקר - Kronecker product

אנו נשתמש במכפלת קרוניקר, בעיקר כדי להפוך משוואות מטריציות (משוואה שבה הנעלם הוא מטריצה) לסט של משוואות סקלריות (על האיברים של המטריצה שמחפשים).

נגדיר את האופרטור הבא (הופך מטריצה לוקטור),

$$\text{vec}(A) = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \end{bmatrix} = \begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{12} \\ a_{22} \\ \vdots \end{bmatrix} \quad \text{נניח,} \quad A = \begin{bmatrix} | & | & \cdots \\ v_1 & v_2 & \cdots \\ | & | & \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \cdots \\ a_{21} & a_{22} & \\ \vdots & & \ddots \end{bmatrix} \quad \text{אז,}$$

$$A = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \Rightarrow \text{vec}(A) = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \quad \text{לדוגמא,}$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

מכפלת קרוניקר - Kronecker product

נגדיר גם אופרטור דומה עבור מטריצות סימטריות.

$$P = \begin{bmatrix} p_{11} & p_{12} & \cdots \\ * & p_{22} & \\ * & * & \ddots \end{bmatrix} \quad \text{נניח } P \in R^{n \times n} \text{ מטריצה סימטרית } (P = P^T), \text{ כך ש}$$

המשולש התחתון במטריצה, מסומן ב- *, , נקבע ע"י המשולש העליון)

לכן במטריצה כזאת יש n^2 איברים, אבל רק $\frac{n(n+1)}{2}$ נעלמים.

האופרטור $\text{svec}(P)$ מסדר את אברי המטריצה $P = P^T$ במערך שהוא ווקטור, אך אינו כולל את האיברים החוזרים בגלל סימטריות.

נגדיר גם את טרנספורמציה הבאה, $\text{vec}(P) = N \text{svec}(P), \quad N \in R^{n^2 \times (n^2+n)/2}$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

מכפלת קרוניקר - Kronecker product

$$\text{svec}(P) = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \end{bmatrix}$$

אז,

$$P = P^T = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 5 \\ 3 & 5 & 6 \end{bmatrix}$$

לדוגמא,

$$\text{vec}(P) = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 2 \\ 4 \\ 5 \\ 3 \\ 5 \\ 6 \end{bmatrix}$$

אבל,

$$\frac{n(n+1)}{2} = \frac{3(3+1)}{2} = 6$$

כאן מספר האיברים ב- $\text{svec}(P)$, הינו

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

מכפלת קרוניקר - Kronecker product

ביחס לדוגמא האחרונה, ניתן להגדיר את מטריצת הטרנספורמציה הבאה, $\text{vec}(P) = N \text{svec}(P)$

$$\begin{array}{c} \begin{matrix} 1 \\ 2 \\ 3 \\ 2 \\ 4 \\ 5 \\ 3 \\ 5 \\ 6 \end{matrix} \end{array} = \underbrace{\begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}}_N \begin{array}{c} \begin{matrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \end{matrix} \end{array}$$

$\text{vec}(P)$ \swarrow \nwarrow $\text{svec}(P)$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

מכפלת קרוניקר - Kronecker product

תכונה חשובה נוספת של מכפלת קרוניקר היא, $\text{vec}(ABC) = (C^T \otimes A) \text{vec}(B)$

על בסיס התכונה הזאת ניתן לכתוב,

$$x^T(t) P_i x(t) = [x^T(t) \otimes x^T(t)] \text{vec}(P_i)$$

לדוגמא, כאשר יש לחשב את אברי המטריצה P_i באלגוריתם איטרטיבי (נציג בהמשך)

אבל מכיוון ש- P_i היא מטריצה סימטרית נכתוב,

$$x^T(t) P_i x(t) = [x^T(t) \otimes x^T(t)] N \text{vec}(P_i)$$

במקרה שלנו, $x(t)$ הינו ווקטור המצב של התהליך המבוקר.

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

$$\dot{x} = Ax + Bu$$

נזכיר כי עבור התהליך,

$$J = \int_0^\infty (x^T Q x + u^T Q u) dt$$

ניתן להגדיר קריטריון ביצוע,

$$V(t) = \int_t^\infty (x^T Q x + u^T Q u) dt$$

וגם פונקציית ערך,

$$u(t) = -K_i x(t)$$

אם משתמשים בבקר מיצב מהצורה,

$$V(t) = x^T(t) P_i x(t)$$

אז פונקציית הערך מקיימת,

$$K_i, P_i \text{ מקיימים משוואת ליאפונוב מהצורה,}$$

כאשר הצמד

$$(A - BK_i)^T P_i + P_i (A - BK_i) + Q + (K_i)^T R K_i = 0$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

באלגוריתם של Kleinman מתחילים עם בקר מייצב K_0 .

ביחס אליו, פותרים את משוואת ליאפנוב,

$$(A - BK_0)^T P_0 + P_0 (A - BK_0) + Q + (K_0)^T R K_0 = 0 \Rightarrow P_0$$

עם הפתרון P_0 מחשבים את הבקר K_1 עבור האיטרציה הבאה,

$$K_1 = R^{-1} B^T P_0$$

והתהליך חוזר על עצמו עד התכנסות, כלומר,

$$(A - BK_1)^T P_1 + P_1 (A - BK_1) + Q + (K_1)^T R K_1 = 0 \Rightarrow P_1$$

וכן' $K_2 = R^{-1} B^T P_1$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

כלומר, באופן כללי,

$$(*) \quad (A - BK_i)^T P_i + P_i (A - BK_i) + Q + (K_i)^T R K_i = 0 \Rightarrow P_i$$

$$(**) \quad K_{i+1} = R^{-1} B^T P_i$$

כאשר האלגוריתם מתכנס, נסמן, $P_{i+1} \cong P_i = P$

אז, $K = R^{-1} B^T P$

אם נציב את ה- K הזה מעלה (במשוואת ליאפנוב), תתקבל משוואת ריקטי

$$A^T P + PA + Q - PBR^{-1}B^T P = 0, \quad P > 0$$

הראינו במצגת קודמת, שעם הפתרון של משוואת ריקטי, $u = -R^{-1}B^T Px$ הוא הבקר האופטימלי.

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

הפתרון של משוואת ליאפונוב בכל איטרציה דורש ידיעה של מודל התהליך (המטריצות A ו- B)

נניח כי מודל התהליך אינו ידוע.

אבל יש לנו סט נתונים (DATA) של התהליך, כלומר אנו יודעים $u(t)$ ו- $x(t)$.

ביחס למודל התהליך, $\dot{x} = Ax + Bu$

ניתן לכתוב, $\dot{x} = Ax + Bu_i + B(u - u_i)$ (הוספנו וחיסרנו Bu_i)

כאשר, $u_i = -K_i x$ (אות הבקר של האיטרציה i)

אם נפעיל את המערכת עם הבקר $u_i = -K_i x$ תתקבל פונקציית הערך

$$V_i(t) = x^T(t) P_i x(t) = \int_t^\infty (x^T Q x + u_i^T R u_i) dt$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

נציב את ביטוי הבקר בפונקציית הערך, נקבל,

$$V_i(t) = x^T(t) P_i x(t) = \int_t^\infty (x^T Q x + x K_i^T Q K_i x) dt$$

$$\dot{V}_i(t) = 2x^T(t) P_i \dot{x}(t) \quad \text{נגזרת בזמן של פונקציית הערך,}$$

כאשר השמטנו את
אינדקס הזמן.

$$\dot{V}_i = 2x^T P_i (Ax + Bu_i + B(u - u_i)) \quad \text{נציב את } \dot{x} \text{ (מהשקף הקודם),}$$

$$\dot{V}_i = 2x^T P_i (Ax - BK_i x + B(u + K_i x)) \quad \text{ועם אות הבקרה,}$$

$$= 2x^T P_i (A - BK_i) x + 2x^T P_i B(u + K_i x)$$

סקלר

סקלר

(לביטוי שהתוצאה שלו סקלר, ניתן לבצע טרנספוז ללא שינוי ערכו)

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

בגלל שני הביטויים הסקלריים בשקף הקודם, ניתן לכתוב,

$$\dot{V}_i = x^T \left((A - BK_i)P_i + P_i(A - BK_i) \right) x + 2(u + K_i x)^T B^T P_i x$$

נשתמש ב- (*) כדי להחליף את $(A - BK_i)^T P_i + P_i(A - BK_i)$ עם $-Q - (K_i)^T R K_i$.

$$\dot{V}_i = -x^T \left(Q + (K_i)^T R K_i \right) x + 2(u + K_i x)^T B^T P_i x \quad \text{נקבל,}$$

$$= -x^T Q_i x + 2(u + K_i x)^T B^T P_i x$$

$$Q_i = Q + (K_i)^T R K_i \quad \text{כאשר}$$

זה הוציא את A מהמשוואה.

גם B^T אינו ידוע, אבל על בסיס (**) ניתן לכתוב, $B^T P_i = R K_{i+1}$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

$$\dot{V}_i = -x^T Q_i x + 2(u + K_i x)^T R K_{i+1} x \quad \text{קיבלנו,}$$

$$= -x^T Q_i x + 2u^T R K_{i+1} x + 2x^T K_i^T R K_{i+1} x$$

נבצע אינטגרציה על שני הצדדים, מ- t עד $t+T$.

$$\int_t^{t+T} \dot{V}_i d\tau = -\int_t^{t+T} x^T Q_i x d\tau + 2\int_t^{t+T} u^T R K_{i+1} x d\tau + 2\int_t^{t+T} x^T K_i^T R K_{i+1} x d\tau$$

נציב,

$$\int_t^{t+T} \dot{V}_i d\tau = V_i(t+T) - V_i(t) = \underbrace{x^T(t+T) P_i x(t+T) - x^T(t) P_i x(t)}$$

הפרש בפונקציית הערך בין
שתי נקודות זמן.

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

קיבלנו,

$$\begin{aligned} & x^T(t+T)P_i x(t+T) - x^T(t)P_i x(t) \\ &= -\int_t^{t+T} x^T Q_i x d\tau + 2\int_t^{t+T} u^T R K_{i+1} x d\tau + 2\int_t^{t+T} x^T K_i^T R K_{i+1} x d\tau \end{aligned}$$

הנעלמים כאן הם P_i ו- K_{i+1} .

(שאר המטריצות ידועות, לדוגמא K_i התקבל באיטרציה קודמת)

המשוואה אינה מתבססת על מטריצות של המודל.

זוהי משוואה סקלרית, לכן משוואה יחידה אינה מספיקה כדי לחשב את כל הנעלמים (הסקלריים)

במטריצות P_i ו- K_{i+1} .

ניתן לייצר מספר משוואות, ע"י שימוש בנתונים השייכים למספר קטעי זמן.

למעשה, אם $x \in R^n, u \in R^m$, יש לייצר לפחות $\frac{n(n+1)}{2} + mn$ משוואות.

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

נשתמש במכפלות קרוניקר כדי לחלץ את הנעלמים,

$$\text{vec}(ABC) = (C^T \otimes A) \text{vec}(B) \quad \text{נזכיר,}$$

אם A ו- C הם ווקטורים, כך ש- ABC הוא סקלר אז,

$$A \cdot B \cdot C = (C^T \otimes A) \text{vec}(B)$$

על בסיס הקשר הזה,

$$2 \int_t^{t+T} u^T R \cdot K_{i+1} \cdot x d\tau = 2 \int_t^{t+T} (x^T \otimes u^T R) d\tau \text{vec}(K_{i+1})$$

$$(A \otimes B)(C \otimes D) = (AC) \otimes (BD) \quad \text{נשתמש גם בתכונה,}$$

$$2 \int_t^{t+T} u^T R \cdot K_{i+1} \cdot x d\tau = 2 \int_t^{t+T} (x^T \otimes u^T) d\tau (I_n \otimes R) \text{vec}(K_{i+1})$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

באופן דומה, נכתוב,

$$2 \int_t^{t+T} x^T K_i^T R \cdot K_{i+1} \cdot x d\tau = 2 \int_t^{t+T} (x^T \otimes x^T) d\tau (I_n \otimes K_i^T R) \text{vec}(K_{i+1})$$

וגם,

$$\int_t^{t+T} x^T Q_i x d\tau = \left(\int_t^{t+T} x^T \otimes x^T d\tau \right) \text{vec}(Q_i)$$

$$\begin{aligned} & x^T(t+T)P_i x(t+T) - x^T(t)P_i x(t) \\ &= [x^T(t+T) \otimes x^T(t+T) - x^T(t) \otimes x^T(t)] N \text{vec}(P_i) \end{aligned}$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

נניח כי נאספו נתונים לאורך קטע זמן $[t_0, t_l]$

נחלק את קטע הזמן ל- l קטעים, כך ש- $l > \frac{n(n+1)}{2} + mn$ (כדי להשיג את מספר המשוואות הדרוש)

נגדיר, $\delta_i = [x(t_{i+1}) \otimes x(t_{i+1}) - x(t_i) \otimes x(t_i)]$

$$\delta_{xx} = [\delta_1, \delta_2, \dots, \delta_{l-1}]^T$$

$$I_{xx} = \left[\int_{t_0}^{t_1} x \otimes x d\tau, \int_{t_1}^{t_2} x \otimes x d\tau, \dots, \int_{t_{l-1}}^{t_l} x \otimes x d\tau \right]^T$$

$$I_{xu} = \left[\int_{t_0}^{t_1} x \otimes u d\tau, \int_{t_1}^{t_2} x \otimes u d\tau, \dots, \int_{t_{l-1}}^{t_l} x \otimes u d\tau \right]^T$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

על בסיס הגדרות אלה, ניתן לכתוב את סט המשוואות הבא,

$$X_i \Theta_i = Y_i$$

נתון – מתבסס על נתונים וכל התוצאה של איטרציה קודמת

כאשר,

$$\begin{cases} X_i = \begin{bmatrix} -\delta_{xx} N, & 2I_{xu} (I_n \otimes R) + 2I_{xx} (I_n \otimes K_i^T R) \end{bmatrix} \\ Y_i = I_{xx} \text{vec}(Q_i) \end{cases}$$

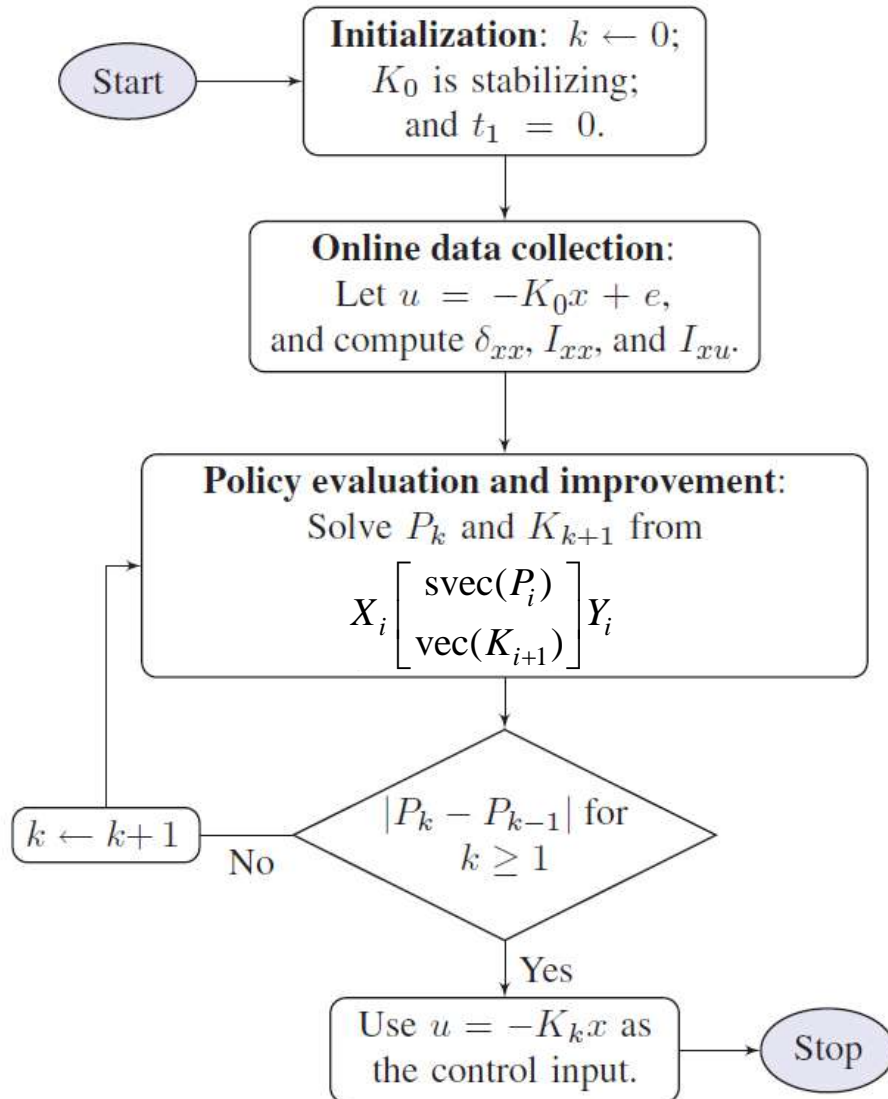
ווקטור נעלמים, מחושב בכל איטרציה מחדש

$$\Theta_i = \begin{bmatrix} \text{svec}(P_i) \\ \text{vec}(K_{i+1}) \end{bmatrix}$$

רצוי לייצר יותר משוואות מנעלמים (בגלל רעש מדידה), לכן הפתרון הוא במובן של ריבועים פחותים, כלומר

$$\Theta_i = (X_i^T X_i)^{-1} X_i^T \cdot Y_i$$

בקר משוב מצב אופטימלי



חישוב איטרטיבי של הבקר האופטימלי הסטצי

אלגוריתם תכנון בקר LQR על בסיס נתונים,

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

דוגמא – נמשיך את הדוגמא שפתרנו קודם, עכשיו נניח שמטריצות המודל אינן ידועות
נזכיר כי מדובר במודל המתאר דינמיקת שגיאות של כלי רכב ביחס למסלול רצוי (קו ישר)
(מתוך -Rajesh Rajamani, “Vehicle Dynamics and Control”, 2012, פרק 2 ע"מ 36)

$$\begin{bmatrix} \dot{e}_1 \\ \ddot{e}_1 \\ \dot{e}_2 \\ \ddot{e}_2 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & -2\frac{C_{\alpha 2} + C_{\alpha 1}}{mv_x} & 2\frac{C_{\alpha 2} + C_{\alpha 1}}{m} & -2\frac{C_{\alpha 2}l_2 - C_{\alpha 1}l_1}{mv_x} \\ 0 & 0 & 0 & 1 \\ 0 & -2\frac{C_{\alpha 2}l_2 - C_{\alpha 1}l_1}{I_{zz}v_x} & 2\frac{C_{\alpha 2}l_2 - C_{\alpha 1}l_1}{I_{zz}} & -2\frac{C_{\alpha 2}l_2^2 + C_{\alpha 1}l_1^2}{I_{zz}v_x} \end{bmatrix} \begin{bmatrix} e_1 \\ \dot{e}_1 \\ e_2 \\ \dot{e}_2 \end{bmatrix} + \begin{bmatrix} 0 \\ \frac{2C_{\alpha 2}}{m} \\ 0 \\ \frac{2C_{\alpha 2}l_2}{I_{zz}} \end{bmatrix} \delta$$

במודל, $e_1(t)$ - שגיאת מקום (של כלי הרכב ביחס למסלול הרצוי).

$e_2(t)$ - שגיאת בכיוון (של כלי הרכב ביחס למסלול הרצוי).

$\delta(t)$ - זווית היגוי (אות הבקרה).

בקר משוב מצב אופטימלי


חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

דוגמא – המשך

דיאגרמת מלבנים של מודל התהליך.

משמש (תחילה) לאיסוף נתונים לצורך תכנון.

המערכת מוזנת עם כניסה אקראית לצורך עירור (Probing noise)



באמצעות ה-switch ניתן
להחליף בין כניסת העירור
לבין כניסת בקר משוב
מצב (אחרי תכנון)

בקר משוב מצב אופטימלי

% Data-base design ADP

%%% Data Collection (from a Simulink model)

sim('Lane_Follow_ADG_LQR')

strt=4000;

t=t_raw(strt:end);

x=x_raw(strt:end,:);

u=u_raw(strt:end,:);

intr=100; %2

delta_xx=[];

for i=intr+1:intr:length(t)-intr;

 x_ti=x(i,:);

 x_tim1=x(i-intr,:);

 delta_xx_i=(kron(x_ti,x_ti)-kron(x_tim1,x_tim1));

 delta_xx=[delta_xx; delta_xx_i];

end

x_kron_x=[]; x_kron_u=[];

for i=1:length(t)

 x_kron_x=[x_kron_x; kron(x(i,:),x(i,:))];

 x_kron_u=[x_kron_u; kron(x(i,:),u(i,:))];

end

I_xu=[]; I_xx=[];

for i=intr+1:intr:length(t)-intr;

 del_i=(i-intr):i;

 I_xu=[I_xu; trapz(t(del_i),x_kron_u(del_i,:))];

 I_xx=[I_xx; trapz(t(del_i),x_kron_x(del_i,:))];

end

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי (המשך)

דוגמא (המשך)

הרצת סימולציה ואיסוף נתונים
(הסימולציה כאן מחליפה הפעלה של
התהליך הממשי לצורך איסוף נתונים)

$$\delta_i = [x(t_{i+1}) \otimes x(t_{i+1}) - x(t_i) \otimes x(t_i)]$$

$$I_{xx} = \left[\int_{t_0}^{t_1} x \otimes x d\tau, \int_{t_1}^{t_2} x \otimes x d\tau, \dots, \int_{t_{l-1}}^{t_l} x \otimes x d\tau \right]^T$$

$$I_{xu} = \left[\int_{t_0}^{t_1} x \otimes u d\tau, \int_{t_1}^{t_2} x \otimes u d\tau, \dots, \int_{t_{l-1}}^{t_l} x \otimes u d\tau \right]^T$$

```

N=zeros(16,10);
N(1,1)=1;N(2,2)=1;N(3,3)=1;N(4,4)=1;
N(5,2)=1;N(6,5)=1;N(7,6)=1;N(8,7)=1;
N(9,3)=1;N(10,6)=1;N(11,8)=1;N(12,9)=1;
N(13,4)=1;N(14,7)=1;N(15,9)=1;N(16,10)=1;

```

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי (המשך)

```
K_i=K1*Error_K_0;
```

```
KK=[]; ii=[]; nPi=[];
```

```
for i=1:20
```

```
    Q_i=[Q+K_i*R*K_i];
```

```
    Y_i=-I_xx*Q_i(:);
```

```
    X_i=[delta_xx*N, -2*I_xx*kron(eye(n),K_i*R)-2*I_xu*kron(eye(n),R)];
```

```
    PK_i=X_i\Y_i;
```

$$\Theta_i = (X_i^T X_i)^{-1} X_i^T \cdot Y_i$$

```
    vecP_i=N*PK_i(1:10);
```

```
    P_i=[vecP_i(1:4) vecP_i(5:8) vecP_i(9:12) vecP_i(13:16)];
```

```
    nPi=[nPi norm(P_i)];
```

```
    K_i=PK_i(11:14)';
```

```
    if norm(P_i_old-P_i)<0.01
```

```
        KK=[KK K_i']; ii=[ii i];
```

```
        break
```

```
    end
```

```
    P_i_old=P_i; KK=[KK K_i']; ii=[ii i];
```

```
end
```

```
K3=K_i
```

```
nPi3=nPi;
```

```
figure(3)
```

```
plot(ii, KK', ii, KK', '*', [ii(1) ii(end)], [K1' K1'], '--', 'linewidth', 1)
```

```
title('Data-based Off-policy, unknown A,B')
```

```
xlabel('Iterations'), ylabel('Control gains'), grid
```

דוגמא (המשך)

K_3 - חישוב מבוסס נתונים בשיטת

Adaptive Dynamic Programing

הנתונים נאספו ממודל Simulink

K1 =

חושב עם הפקודה lqr

1.0000	0.0901	1.9791	0.1333
--------	--------	--------	--------

K2 = **חושב עם האלגוריתם של Kleinman**

1.0000	0.0901	1.9791	0.1333
--------	--------	--------	--------

K3 =

חישוב מבוסס נתונים בשיטת ADP

1.0000	0.0902	1.9819	0.1340
--------	--------	--------	--------

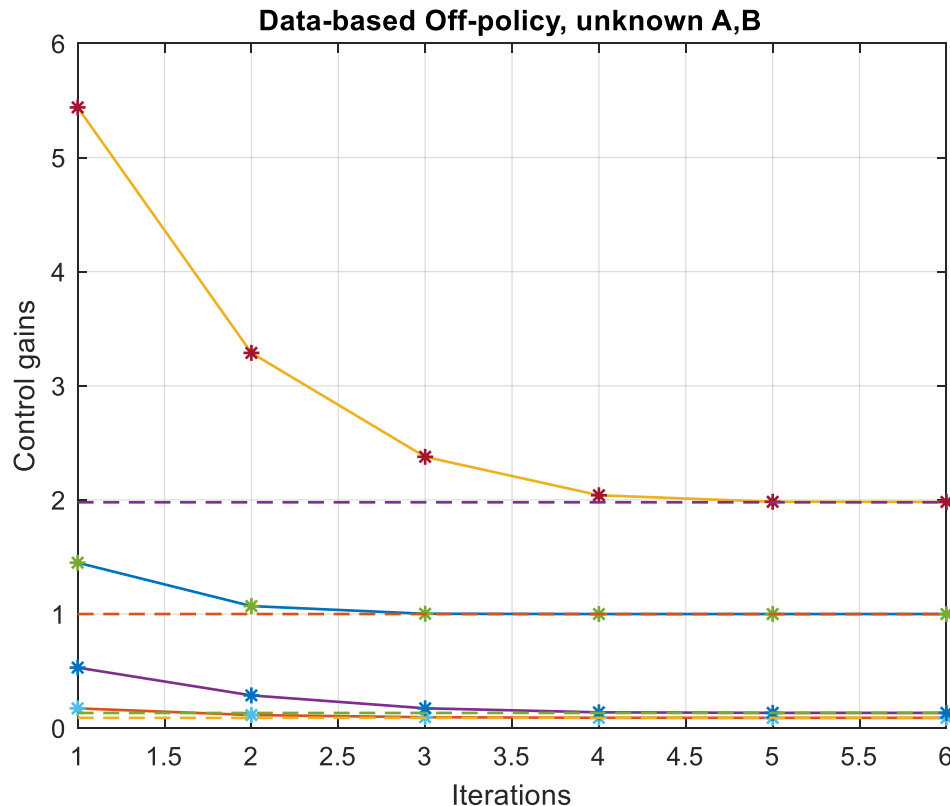
fx >> |

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי (המשך)

דוגמא (המשך)

Figure 3



התכנסות הגברי הבקר אל
הערכים האופטימליים (מוצגות
6 איטרציות).

ניתן לראות כי תהליך ההתכנסות כאן
(מבוסס נתונים וללא שימוש במודל),
זהה לתהליך ההתכנסות של
האלגוריתם האיטרטיבי של -
Kleinman (הוצג קודם ב- Figure 1)

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

נציג את פיתוח משוואות התכנון **למקרה הלא ליניארי** (כאשר המודל אינו ידוע – כלומר תכנון מבוסס נתונים)

מודל התהליך נתון ע"י, $\dot{x} = f(x) + g(x)u$ עם $f(0) = 0$

$$x \in R^n, u \in R^m$$

מעוניינים בבקר אופטימלי במובן הבא,

$$h(0) = 0, R > 0 \quad \text{עם} \quad J(u^*) = \min_u \int_0^\infty (h^T(x)h(x) + u^T R u) dt$$

$$u^*(x) = -\frac{1}{2} R^{-1} g^T(x) \nabla V(x) \quad \text{הראינו כי,}$$

$$\nabla V^T f(x) + h^T(x)h(x) - \frac{1}{4} \nabla V^T(x) g(x) R^{-1} g^T(x) \nabla V(x) = 0 \quad \text{כאשר,}$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

תחילה יש צורך בהרחבה של האלגוריתם של Kleinman למקרה הלא ליניארי.

אם נפעיל בקר u_i מייצב וכזה שעבורו פונקציית המחיר מקבלת ערך סופי (admissible), ניתן לכתוב,

$$V_i(t) = \int_t^\infty \left(h^T(x)h(x) + u_i^T R u_i \right) dt$$

מגזירה של המשוואה בזמן,

$$\dot{V}_i = \nabla V_i^T(x) \dot{x} = -h^T(x)h(x) - u_i^T R u_i$$

נציב את מודל התהליך (מתקבלת משוואת Bellman),

$$\nabla V_i^T(x) [f(x) + g(x)u_i] + h^T(x)h(x) + u_i^T R u_i = 0$$

(Policy evaluation)

עבור u_i נתון, ניתן לפתור משוואה זו לחישוב $V_i(x)$ עם תנאי הסף $V_i(0) = 0$.

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

המשוואה האחרונה (Policy evaluation) היא המקבילה למשוואת ליאפונוב מהמקרה הליניארי

$$(A - BK_i)^T P_i + P_i (A - BK_i) + Q + (K_i)^T R K_i = 0 \Rightarrow P_i$$

שאפשרה לחשב את P_i עבור בקרה מסוים K_i (למעשה לאמוד את טיבו).

עכשיו, עם $V_i(x)$ שחישבנו עבור הבקרה u_i , ניתן "לקדם" את חוק הבקרה באופן הבא,

$$(Policy\ improvement) \quad u_{i+1}(x) = -\frac{1}{2} R^{-1} g^T(x) \nabla V_i(x)$$

זה שקול, במקרה הליניארי, ל- $K_{i+1} = R^{-1} B^T P_i$

הרחבה של התיאוריה של Kleinman קובעת, $V^*(x) \leq V_{i+1}(x) \leq V_i(x)$

וגם ש- $u_i(x)$ הם בקרים מייצבים.

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

ההרחבה של לחישוב הבקר, דורשת ידיעה של מודל התהליך.

נפתח אלגוריתם מבוסס נתונים, דומה לזה שהצגנו עבור המקרה הליניארי.

אלגוריתמים מבוססי נתונים מהסוג שאנו מציגים כאן נקראים,

Off-policy reinforcement learning

(כי הנתונים המשמשים לקידום ה-policy אינם התקבלו ע"י הפעלת ה-policy הקודם בתהליך)

כמו במקרה הליניארי, גם כאן, נרשום את המודל באופן הבא,

$$\dot{x} = f(x) + g(x)u_i + g(x)(u - u_i) \quad (\text{הוספנו וחיסרנו } g(x)u_i)$$

כאשר, u_i , אות הבקר של האיטרציה i .

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

מגזירה של פונקציית הערך, והצבת מודל התהליך (עם הניסוח החדש),

$$\begin{aligned}\dot{V}_i(x) &= \nabla V_i^T(x) \dot{x} = \nabla V_i^T(x) [f(x) + g(x)u_i + g(x)(u - u_i)] \\ &= \underbrace{\nabla V_i^T(x) [f(x) + g(x)u_i]}_{\text{מודל התהליך אינו ידוע, אבל ההרחבה של}} + \underbrace{\nabla V_i^T(x) g(x)(u - u_i)}_{\text{התיאוריה של Kleinman מאפשרת לרשום,}}\end{aligned}$$

(משוואת Bellman)

$$\nabla V_i^T(x) [f(x) + g(x)u_i] = -h^T(x)h(x) - u_i^T R u_i$$

$$\underbrace{u_{i+1}(x) = -\frac{1}{2} R^{-1} g^T(x) \nabla V_i(x)}$$

$$\nabla V_i^T(x) g(x) = -2u_{i+1}^T(x) R$$

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

אחרי הצבות, קיבלנו

$$\dot{V}_i(x(x)) = -h^T(x)h(x) - u_i^T R u_i - 2u_{i+1}^T(x)R(u - u_i)$$

נבצע אינטגרציה על שני הצדדים, מ- t עד $t + T$.

$$\int_t^{t+T} \dot{V}_i d\tau = - \int_t^{t+T} h^T(x)h(x) d\tau - \int_t^{t+T} u_i^T R u_i d\tau - 2 \int_t^{t+T} u_{i+1}^T(x)R(u - u_i) d\tau$$

$$V_i(x(t+T)) - V_i(x(t)) = - \int_t^{t+T} h^T(x)h(x) d\tau - \int_t^{t+T} u_i^T R u_i d\tau - 2 \int_t^{t+T} u_{i+1}^T(x)R(u - u_i) d\tau$$

הנעלמים כאן הם $V_i(x)$ ו- $u_{i+1}(x)$ (כמו במקרה הליניארי שם חישבנו P_i ואת K_{i+1} במקביל, המשמעות היא שמבצעים גם את ה- **Policy evaluation** וגם את **Policy improvement** במקביל).

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

במקרה הליניארי, ידענו כי $V_i(x) = x^T P_i x$

(ידענו את הצורה של פונקציית הערך, וחישבנו את המטריצה P_i של הפתרון האופטימלי)

במקרה הלא ליניארי, לא ניתן לקבוע את הצורה של $V(x)$ באופן כללי.

מכיוון שרשרת נוירונים יכולה להוות קירוב של כל פונקציה לא ליניארית כלשהי, נשתמש בקרובים הבאים,

$$\hat{V}_i(x) = \sum_{j=1}^{N_1} \hat{c}_{i,j} \phi_j(x) = \hat{C}_i^T \phi(x)$$

$$\hat{u}_{i+1}(x) = \sum_{j=1}^{N_2} \hat{w}_{i,j} \psi_j(x) = \hat{W}_i^T \psi(x)$$

$\phi(x), \psi(x)$ - ווקטורים של פונקציות בסיס בלתי תלויות (לדוגמא, פונקציות אקטיבציה של NN)

\hat{C}_i, \hat{W}_i - ווקטורים של משקלים לא ידועים.

בקר משוב מצב אופטימלי

חישוב איטרטיבי של הבקר האופטימלי הסטציונרי

נציב את הקרובים,

$$\sum_{j=1}^{N_1} \hat{c}_{i,j} \left[\phi_j(x(T+t)) - \phi_j(x(t)) \right] =$$
$$-\underbrace{\int_t^{t+T} \left[h^T(x)h(x) + u_i^T R u_i \right] d\tau}_{\text{ידוע}} - 2 \int_t^{t+T} \sum_{j=1}^{N_2} \hat{w}_{i,j} \psi_j^T(x) R (u - u_i) d\tau$$

נעלמים

נעלמים

אית הבקרה שחושב באיטרציה קודמת

יש לאסוף מספיק נתונים כדי לייצר מספיק משוואות לפתרון הנעלמים $\hat{c}_{i,j}, \hat{w}_{i,j}$.

כמו במקרה הליניארי, כל משוואה מתקבלת מתוך אינטגרציה על קטע זמן t עד $t+T$.

(למעשה יש צורך בלפחות $N_1 + N_2$ קטעי זמן)